

Tention PTX Early Detection

강동우, 강민혁, 채상윤, 최서영
DataAnalytics Team7

Abstract

긴장성 기흉은 중환자실 환경에서 즉각적인 의료 개입이 필요한 생명을 위협하는 응급 상황이다. 본 프로젝트는 MIMIC-IV 데이터베이스를 활용하여 생체 신호 및 동맥혈 가스 분석 데이터로부터 긴장성 기흉의 조기 징후를 탐지하는 머신러닝 모델을 개발하였다. 총 4,667명의 환자 데이터로부터 256개의 시계열 특성을 추출하였으며, 도메인 지식 기반 파생 변수 및 고차 통계 특성을 포함하였다. 데이터 품질 확보를 위해 탐욕적 샘플 제거 알고리즘과 비대칭 임계값 기반 특성 선택을 적용하였으며, MICE 기법을 통한 다중 대체로 결측치를 처리하였다. XGBoost와 LightGBM 모델을 Optuna 프레임워크로 최적화하였으며, Focal Loss와 Cost-sensitive Learning을 통해 클래스 불균형 문제를 해결하였다. 5-fold 교차 검증 결과, XGBoost 모델이 AUROC 0.7457, AUPRC 0.6623, F1-score 0.6679를 달성하여 가장 우수한 성능을 보였다. 특히 Recall 0.7276을 기록하여 조기 탐지라는 임상적 목적에 부합하는 결과를 나타냈다. 본 프로젝트는 실시간 생체 신호 모니터링을 통한 긴장성 기흉의 조기 정보 시스템 구축 가능성을 제시한다.

Keywords: 긴장성 기흉, 조기 탐지, 머신러닝, XGBoost, 생체 신호 분석, MIMIC-IV

1 Introduction

긴장성 기흉(Tension Pneumothorax, Tension PTX)은 흉막강 내에 공기가 축적되어 폐가 허탈되고, 종격동이 편위되며, 정맥 환류가 감소하여 심혈관계 허탈을 초래하는 치명적인 응급 질환이다. 중환자실 환경에서는 기계 환기, 중심 정맥 카테터 삽입 등의 침습적 시술 중 의인성 기흉이 발생할 위험이 높으며, 신속한 진단과 치료가 이루어지지 않을 경우 수분 내에 사망에 이를 수 있다.

전통적으로 긴장성 기흉의 진단은 임상적 징후(경정맥 확장, 기관 편위, 저혈압)를 바탕으로 한 의사의 판단과 영상 검사(흉부 X-ray, CT)에 의존해왔으나, 이러한 방법은 기존에 기흉 병력이 있었거나, 증상이 명확해진 후에야 확인 가능하다는 한계가 있다. 특히 중환자실 환자의 경우 진정 상태 또는 의식 저하로 인해 주관적 증상 호소가 어렵고, 다양한 기저 질환으로 인해 생체 신호의 변화가 비특이적으로 나타나 조기 발견이 더욱 어렵다.

최근 의료 빅데이터와 머신러닝 기술의 발전으로 생체 신호의 미세한 패턴 변화를 분석하여 임상적 악화를 예측하는 연구가 활발히 진행되고 있다(Rajkomar et al., 2019). 특히 MIMIC(Medical Information Mart for Intensive Care) 데이터베이스는 중환자실 환자의 대규모 의료 데이터를 제공하여 다양한 예측 모델 개발의 기반이 되고 있다(Johnson et al., 2016).

본 프로젝트는 MIMIC-IV 데이터베이스를 활용하여 흉관 삽입이 필요한 임상적으로 유의미한 기흉 환자를 대상으로, 생체 신호의 시계열 패턴 분석을 통해 긴장성 기흉의 조기 탐지 가능성을 검증하고자 한다. 이를 위해 도메인 지식 기반의 특성 공학, 강건한 전처리 파이프라인, 그리고 불균형 데이터 학습에 최적화된 머신러닝 모델을 구축하였다.




Figure 1: 긴장성 기흉 예시

2 Method

2.1 Data Collection and Cohort Definition

2.1.1 Data Sources

본 프로젝트는 교수님께서 제공해주신 SQLite 형태의 MIMIC-IV v2.2 데이터베이스와 MIMIC-CXR v2.0 영상 라벨 데이터를 활용하였다. MIMIC-IV는 2008년부터 2019년까지 Beth Israel Deaconess Medical Center의 중환자실에 입원한 환자의 비식별화된 의료 기록을 포함한다(Johnson et al., 2023).

2.1.2 Cohort Selection Criteria

긴장성 기흉 조기 탐지 모델 학습을 위해 임상 기록 및 영상 검사 결과를 종합하여 신뢰도 수준에 따라 환자군을 세 가지 코호트로 분류하였다(Table 1). 각 코호트는 ICD 진단 코드, 시술 코드, 그리고 흉부 X-ray 영상 라벨(CheXpert, NegBio)의 조합으로 정의되었다.

GOLD 코호트는 가장 높은 신뢰도를 가진 실험군으로, 기흉 관련 ICD 진단 코드(ICD-9: 512%, ICD-10: J93%, S270%/S27.0%)와 함께 흉관 삽입 시술 코드(ICD-9 Procedure: 3491, 3404)가 모두 확인된 환자를 포함한다. 흉관 삽입술은 임상적으로 중등도 이상의 기흉에서 시행되는 침습적 치료이므로, 이 군은 긴급한 치료가 필요한 기흉 환자로 간주할 수 있다.

SILVER 코호트는 기흉 진단 코드는 있으나 흉관 삽입 시술은 시행되지 않았으며, CheXpert 또는 NegBio 라벨링 시스템 중 하나 이상에서 기흉이 양성으로 확인된 환자군이다. 이 코호트는 경증에서 중등도의 기흉으로 추정되며, 보존적 치료(관찰, 산소 요법 등)로 관리된 것으로 간주된다.

CLEAN 코호트는 음성 대조군으로, 기흉 관련 진단 코드 및 흉관 삽입 시술 기록이 전혀 없고, CheXpert와 NegBio 영상 라벨 모두에서 기흉이 음성(Pneumothorax \neq 1.0)으로 확인된 환자를 포함한다. 이 코호트는 기흉이 없음이 임상 기록과 영상 소견 모두에서 확인되어 가장 신뢰할 수 있는 대조군이며, 표본 크기가 가장 크다. 데이터 불균형 해소를 위해 전체 대조군 중 약 5%를 무작위 샘플링하여 최종 분석에 사용하였다.

Table 1: Cohort Definition and Selection Criteria

Cohort	ICD Diagnosis Code	ICD Code	Procedure	Radiology
GOLD (Experimental)	ICD-9: 512% ICD-10: J93%, S270%	ICD-9 Proc: 3491, 3404		-
SILVER (Diagnosis Confirmed)	ICD-9: 512% ICD-10: J93%, S270%	None		CheXpert or NegBio Positive
CLEAN (Control)	None	None		CheXpert and NegBio Negative

2.1.3 Reference Time Definition

조기 탐지 모델 학습을 위해 각 환자의 입원별로 데이터 추출의 기준이 되는 시점(t_{ref})을 정의하였다. 실험군의 경우 흉관 삽입술이 시행된 시점을 기준 시점으로 설정하였다. 대조군의 경우 입원 극 초기의 불안정한 상태를 배제하기 위해 입원 시점으로부터 24시간이 경과한 시점을 기준 시점으로 설정하였다.

2.2 Biological Signal and Clinical Variable Extraction

2.2.1 Target Variables

임상적 중요도와 데이터 가용성을 고려하여 호흡기 및 혈액학적 상태를 반영하는 주요 변수를 선정하였다(Table 2).

Table 2: Extracted Biological Signals and Clinical Variables

Category	Variable	Description	Main ITEMID
Vital Sign	HR	Heart Rate	220045
	RR	Respiratory Rate	220210, 224690
	SpO2	Oxygen Saturation	220277
	SBP/DBP	Systolic/Diastolic Blood Pressure	220179, 220180
	FiO2	Inhaled Oxygen Concentration	223835, 227009
Arterial Blood Gas	pH	Blood pH	50820
	PaO2	Arterial Oxygen Pressure	50821
	PaCO2	Arterial Carbon Dioxide Pressure	50818
	HCO3	Bicarbonate	50882

2.2.2 Time Window

설정된 기준 시점(t_{ref})을 기준으로 과거 3시간 동안의 데이터를 관측 윈도우로 설정하여 추출하였다.

$$t_{ref} - 3h \leq t_{chart} \leq t_{ref}, \quad \text{where } t_{ref} \geq t_{admit} + 3h \quad (1)$$

2.3 Feature Engineering

2.3.1 Domain Knowledge-based Derived Variables

단일 변수만으로는 포착하기 어려운 환자의 혈액학적 불안정성과 호흡 부전 상태를 복합적으로 반영하기 위해 임상 지표를 계산하였다(Table 3).

Table 3: Domain Knowledge-based Derived Variables

Category	Variable	Formula/Definition	Clinical Significance
Hemodynamics	MAP	$DBP + \frac{1}{3}(SBP - DBP)$	Mean arterial pressure, indicator of organ perfusion
	Pulse Pressure	$SBP - DBP$	Pulse pressure, reflects cardiovascular stiffness
	Shock Index	HR/SBP	Early warning for acute hemorrhage and septic shock
	MSI	HR/MAP	Modified shock index
Respiratory	P/F Ratio	PaO_2/FiO_2	Severity classification criterion for ARDS
	ROX Index	$(SpO_2/FiO_2)/RR$	Predictor of high-flow nasal cannula therapy success
	AA Gradient	$PAO_2 - PaO_2$	Alveolar-arterial oxygen pressure difference
	RDI	$RR/SpO_2 \times 100$	Respiratory distress index

2.3.2 Time Series Feature Analysis

이벤트 발생 전 생체 신호의 미세한 변화를 포착하기 위해 고차 통계량과 신호 복잡도를 나타내는 특성을 추출하였다. 먼저, 데이터 분포의 비대칭도(Skewness)와 꼬리의 두께(Kurtosis)를 계산하여 급격한 값의 변화나 이상치 발생 경향을 정량화하였다. 변동성 동역학을 평가하기 위해 인접한 측정값 간 차이의 제곱평균제곱근(RMSSD, Root Mean Square of Successive Differences)과 중위수 절대 편차(MAD, Median Absolute Deviation)를 산출하였다. 또한 생체 신호의 규칙성과 복잡성을 측정하기 위해, 즉, 병리학적 상태에서 신호가 지나치게 규칙적이거나 무질서해지는 경향을 반영하기 위해 샘플 엔트로피를 계산하였다. 마지막으로 비모수적 추세 검정인 Mann-Kendall Tau를 적용하여 관측 윈도우 내에서 수치가 일관되게 증가하거나 감소하는 경향성을 정량화하였다.

2.3.3 Multiple Time Window

임박한 이벤트의 조기 징후를 포착하면서도 전반적인 환자 상태의 변화 추이를 반영하기 위해, 기준 시점으로부터 30분, 60분, 120분의 세 가지 시간 윈도우를 설정하였다. 각 윈도우별로 통계적 특성을 독립적으로 추출하여, 모델이 생리학적 악화의 시간적 패턴을 학습할 수 있도록 하였다. 모든 시간 윈도우와 변수를 결합하여 총 256개의 특성이 추출되었다. 추출된 특성의 상세 목록은 함께 위치한 부록(Appendix.pdf)에 제시하였다.

2.4 Data Preprocessing

2.4.1 Greedy Sample Removal based Data Quality Assurance

일반적으로 결측률이 높은 특성을 일괄 삭제하면 중요한 임상 정보를 잃을 위험이 있다. 본 프로젝트에서는 대조군의 샘플 수가 충분하다는 점에 착안하여, 특성을 보존하기 위해 질 낮은 대조군 샘플을 제거하는 탐욕적 샘플 제거 알고리즘을 제안 및 적용하였다. 이 알고리즘은 특정 특성의 결측률이 허용 임계값($\theta_{control} = 50\%$)을 초과할 경우, 해당 결측에 대한 기여도가 높은 대조군 샘플을 우선적으로 반복 제거하는 방식으로 작동한다. 이를 통해 대조군 샘플 크기를 일부 희생하더라도 희소한 실험군을 유지하면서 모델링에 사용할 가능한 유효 특성의 수를 최대화하였다.

2.4.2 Asymmetric Threshold-based Feature Selection

희소한 실험군 데이터와 풍부한 대조군 데이터의 특성을 고려하여, 특성 선정 기준에 비대칭 임계값을 적용하였다. 실험군의 경우 희소한 양성 환자 데이터를 최대한 보존하기 위해 결측률이 65% 미만인 특성을 유지하였다. 반면 대조군에는 고품질 데이터만을 선별하고 학습 안정성을 확보하기 위해 50%라는 더 엄격한 임계값을 적용하였다. 이러한 비대칭적 접근법은 희귀 질환 사례로부터 최대한의 정보를 추출하면서도, 더 큰 규모의 대조군에 대해서는 데이터 품질 기준을 유지하는 균형을 이루었다.

2.4.3 Multiple Imputation for Missing Values

단순 평균 대체법이 야기하는 변수 간 상관관계 왜곡과 분산 축소 문제를 방지하기 위해, 특히, 의료 도메인에서 생체 신호 간의 다변량 상관관계를 학습하여 생리학적으로 타당한 값을 생성해낼 수 있도록 MICE(Multivariate Imputation by Chained Equations) 기법을 적용하였다(van Buuren and Groothuis-Oudshoorn, 2011). 단일 대체의 편향을 줄이기 위해 서로 다른 난수 시드를 적용하여 5개의 독립적인 대체 데이터셋을 생성하였으며, 이들의 평균값을 최종 결측 보정값으로 사용하였다.

2.4.4 Normalization

StandardScaler를 적용하여 모든 특성의 평균을 0, 표준편차를 1로 정규화하였다.

2.4.5 Final Dataset Construction

전처리 이후, SILVER 코호트를 배제하고 확진된 GOLD 코호트와 정제된 CLEAN 코호트만을 사용하여 최종 데이터셋을 구성하였다. 최종적으로 결측치가 존재하지 않는 완전한 데이터셋이 생성되었다.

2.5 Machine Learning Pipeline

2.5.1 Feature Selection

Permutation Importance 기반의 특성 선택을 수행하였다(반복 횟수: 5회). 최종적으로 총 256개의 특성 중 76개의 유의미한 특성이 모델 학습에 사용되었다. 사용한 특성의 상세 목록은 함께 위치한 부록(Appendix.pdf)에 제시하였다.

2.5.2 Cost-sensitive Learning for Class Imbalance

실제 임상 환경에서는 실험군보다 대조군이 훨씬 많다는 점을 고려하여, 별도의 합성 샘플 생성 기법을 적용하지 않고 Cost-sensitive Learning 방식을 채택하였다. 소수 클래스 가중치 최적화를 위해 모델의 `scale_pos_weight` 파라미터를 제어하는 승수를 Optuna TPE 샘플러로 5.0에서 25.0 범위에서 탐색하였으며, 최종 가중치는 다음과 같이 계산하였다.

$$\text{scale_pos_weight} = \frac{n_{\text{negative}}}{n_{\text{positive}}} \times \text{multiplier} \quad (2)$$

또한 불균형 데이터 학습의 효율성을 높이기 위해 Focal Loss를 도입하였다 Lin et al., 2017. Focal Loss는 쉽게 분류되는 샘플의 손실 가중치를 줄이고, 어려운 샘플에 집중하도록 설계된 손실 함수로, 다음과 같이 정의된다.

$$\text{FL}(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (3)$$

여기서 p_t 는 올바른 클래스에 대한 예측 확률이며, α_t 는 클래스별 가중치, γ 는 focusing parameter이다. p_t 와 α_t 는 다음과 같이 정의된다.

$$p_t = \begin{cases} p & \text{if } y = 1 \\ 1 - p & \text{if } y = 0 \end{cases}, \quad \alpha_t = \begin{cases} \alpha & \text{if } y = 1 \\ 1 - \alpha & \text{if } y = 0 \end{cases} \quad (4)$$

본 연구에서는 $\alpha = 0.25$, $\gamma = 2.0$ 을 사용하였으며, XGBoost와 LightGBM 모두에서 objective function으로 구현하여 적용하였다.

2.5.3 Cross-validation

강건한 모델 학습을 위해 동일 환자의 데이터가 학습 데이터와 검증 데이터에 동시에 포함되지 않도록 GroupKFold 방식을 사용하여 데이터를 분리하여 학습한 후, 일반화 성능을 평가하였다(5-Fold).

2.5.4 Model Selection and Hyperparameter Optimization

본 프로젝트에서는 XGBoost와 LightGBM을 사용하였다. 하이퍼파라미터 최적화는 Optuna 프레임워크 Akiba et al., 2019를 활용하였으며, Tree-structured Parzen Estimator Sampler를 탐색 알고리즘으로 채택하였다. 비효율적인 하이퍼파라미터 조합의 조기 종료를 위해 MedianPruner를 적용하였으며, 과적합 방지를 위해 검증 성능이 30라운드 동안 향상되지 않을 경우 학습을 조기 종료하도록 설정하였다. 각 모델에 대해 100회의 최적화 시도를 수행하였으며, 최적화 목표 지표로 LogLoss를 최소화하도록 설정하였다.

2.5.5 Threshold Optimization

기본 임계값(0.5) 대신, 각 Fold 및 모델별로 F1-score를 최대화하는 최적 임계값을 탐색하여 적용하였다.

2.5.6 Ensemble Strategy

단일 모델의 한계를 극복하고 예측 안정성을 높이기 위해 두 가지 앙상블 전략을 적용하였다. Soft Voting 방식에서는 XGBoost와 LightGBM의 예측 확률값을 가중 평균하였으며, 0.00에서 1.00 범위에서 가중치를 탐색하여 AUROC를 최대화하는 최적 가중치를 선정하였다. Stacking 방식에서는 XGBoost와 LightGBM을 Base model로 사용하고, 이들의 예측 확률값을 메타 특성으로 하여 Logistic Regression을 Meta-learner로 학습시켰다. Meta-learner의 최적화는 L-BFGS solver와 정규화 파라미터 $C=1.0$ 를 사용하였다.

3 Results

3.1 Optimal Hyperparameters

Optuna 최적화를 통해 도출된 각 모델의 최적 하이퍼파라미터는 Table 4와 같다. 파이프라인 전체에서 사용된 하이퍼파라미터의 상세 목록은 최적 하이퍼파라미터 값은 함께 위치한 부록(Appendix.pdf)에 제시하였다.

Table 4: Optimal Hyperparameters Results

Parameter	XGBoost	LightGBM
n_estimators	158	263
max_depth	4	7
learning_rate	0.0411	0.0122
pos_weight_multiplier	13.21	17.69

3.2 Model Performance Evaluation

5-fold 교차 검증을 통해 평가된 모델별 성능은 Table 5와 같다.

Table 5: Model Performance Comparison (Mean \pm SD)

Model	AUROC	AUPRC	F1-score	Precision	Recall	Accuracy
XGBoost	0.7457 (± 0.0238)	0.6623 (± 0.0563)	0.6679 (± 0.0516)	0.6764 (± 0.0338)	0.7276 (± 0.1147)	0.7678 (± 0.0288)
LightGBM	0.7103 (± 0.0310)	0.6411 (± 0.0653)	0.6292 (± 0.0405)	0.6512 (± 0.0516)	0.6844 (± 0.1144)	0.7344 (± 0.0927)
Soft Voting	0.7324 (± 0.0324)	0.6607 (± 0.0511)	0.6502 (± 0.0465)	0.6410 (± 0.0625)	0.6934 (± 0.0682)	0.7167 (± 0.0621)
Stacking	0.7324 (± 0.0324)	0.6607 (± 0.0511)	0.6502 (± 0.0465)	0.6410 (± 0.0625)	0.6934 (± 0.0682)	0.7167 (± 0.0621)

3.3 Key Predictive Features

Permutation Importance 기반으로 선정된 상위 5개 특성은 Table 6와 같다.

Table 6: Key Predictive Features (XGBoost)

Feature Name	Importance	Clinical Significance
w120_RR_kurt	0.0417	Kurtosis of respiratory rate over the past 2 hours. Captures abrupt changes or irregularities in breathing patterns preceding tension pneumothorax
all_SHOCK_INDEX_kurt	0.0300	Kurtosis of shock index over the entire observation period. Cardiovascular stress from pneumothorax manifests as rapid fluctuations in shock index
all_RR_kurt	0.0291	Kurtosis of respiratory rate over the entire observation period. Instability of breathing patterns throughout the 3-hour window
w120_SpO2_mad	0.0265	Median absolute deviation of SpO ₂ over the past 2 hours. Increased variability in oxygen saturation during ventilation impairment caused by pneumothorax
w120_DBP_kurt	0.0245	Kurtosis of diastolic blood pressure over the past 2 hours. Tension pneumothorax reduces venous return to the heart, causing blood pressure instability




Figure 2: Top 5 features ranked by permutation importance in (A) XGBoost and (B) LightGBM. RR: respiratory rate; MAD: median absolute deviation; DBP: diastolic blood pressure; MAP: mean arterial pressure; RMSSD: root mean square of successive differences.

4 Discussion

4.1 Interpretation

본 프로젝트에서 개발한 XGBoost 기반 긴장성 기흉 조기 탐지 모델은 AUROC 0.7457, Recall 0.7276을 달성하였다. 특히 Recall 72.76%는 실제 긴장성 기흉 환자의 약 73%를 조기에 탐지할 수 있음을 의미하며, 이는 생명을 위협하는 응급 상황에서 거짓 음성을 최소화하는 것이 중요한 임상적 목표를 고려할 때 유의미한 수준이라 판단된다. AUROC 0.7457은 모델이 무작위 분류기(0.5)보다 현저히 우수하며, 이와 같은 불균형 데이터셋을 고려하면 특히 더 좋은 결과라고 판단된다.

주요 예측 특성 분석 결과는 긴장성 기흉의 병태생리학적 특징과 일치하는 패턴을 보였다. 첫째, 상위 5개 특성 중 4개가 kurtosis로 나타났다. 이는 긴장성 기흉은 흉막강 내 압력이 급격히 증가하여 폐 허탈과 종격동 편위를 유발하는 급성 병리 현상이므로, 환자의 생체 신호가 정상 범위를 벗어나 급격히 변동하는 경향을 보인다. 따라서 kurtosis가 높은 값을 가지는 특성들이 주요 예측 인자로 선정된 것은 이 질환의 급성 발현 특성을 반영한 것으로 해석된다.

또한, 상위 5개 특성 중 3개가 120분(2시간) 시간 윈도우에서 추출되었다. 이는 30분 단기 윈도우나 180분(3시간) 전체 윈도우보다 중간 범위의 시간 척도가 더 높은 예측력을 보임을 의미한다. 30분 윈도우는 측정 오차나 일시적 변동에 취약할 수 있으며, 180분 윈도우는 초기의 안정적인 상태를 포함하여 이벤트 직전의 변화를 희석시킬 수 있다. 반면 120분 윈도우는 병리학적 변화가 본격적으로 진행되는 시기를 포착하면서도 충분한 데이터 포인트를 확보하여 통계적 안정성을 유지하는 최적 구간으로 판단된다.

그리고, 호흡수(Respiratory Rate) 관련 특성이 나머지를 차지하였다. 긴장성 기흉의 핵심 병태생리는 환기-관류 불균형과 폐 허탈로 인한 호흡 부전이며, 이는 심박수나 혈압의 변화보다 선행하는 것으로 알려져 있다. 환자는 저산소증에 대한 보상 기전으로 호흡수를 증가시키며, 흉막강 내 압력 변동으로 인해 호흡 패턴의 불규칙성이 나타난다. 따라서 호흡수의 침도가 주요 예측 인자로 식별된 것은 긴장성 기흉의 임상적 발현 순서와 일치하며, 호흡기계 모니터링이 조기 경보 시스템에서 핵심적 역할을 할 수 있음을 시사한다.

4.2 Methodological Strengths

4.2.1 Greedy Sample Removal Algorithm

의료 데이터에서는 특성 간 상호의존성이 높아 단순 특성 제거 시 임상적으로 중요한 정보가 손실될 수 있다. 탐욕적 샘플 제거 알고리즘 기반한 제안한 특성 추출 방식은 listwise deletion이나 완전 특성 제거와 달리, 동맥혈 가스 분석과 같이 임상적으로 핵심적인 변수들을 보존하면서도 결측률이 높은 샘플만 선택적으로 제거한다.

이를 통해 특성 기반 접근법들이 가진 정보 손실 문제를 해결하고, 의료진의 임상적 판단에 필수적인 생체 지표들을 온전히 유지할 수 있었다. 알고리즘은 각 샘플의 결측 패턴을 분석하여 전체 데이터셋의 통계적 대표성을 훼손하지 않는 범위에서 최적의 샘플을 제거하도록 설계되었다.

4.2.2 Asymmetric Threshold-based Feature Selection

중환자실 데이터는 본질적으로 클래스 불균형을 내포하며, 희소한 실험군과 풍부한 대조군 간 데이터 특성이 상이하다. 단일 임계값 기반 방법은 이러한 비대칭성을 고려하지 못해 소수 클래스의 중요 특성을 과도하게 제거할 위험이 있다.

비대칭 임계값 전략은 각 클래스별로 독립적인 결측률 기준을 설정하여, 희귀 질환군에서는 더 관대한 임계값을 적용하고 대조군에서는 엄격한 기준을 적용한다. 이를 통해 symmetric feature selection이나 class-agnostic filtering 등에서 발생하는 편향을 최대한 방지하고자 하였으며, 결과적으로 클래스별 임상적 특성을 균형있게 보존할 수 있었다.

4.2.3 MICE

의료 생체 신호는 생리학적 메커니즘에 의해 강한 다변량 상관관계를 보이며, 단순 대체 방법으로는 이러한 관계를 재현할 수 없다. Mean/median imputation이나 forward fill 같은 단변량 방법은 변수 간 의존성을 무시하여 비현실적인 값을 생성할 수 있다. 이와는 다르게 MICE는 조건부 확률분포를 학습하여 혈압-심박수, 산소포화도-호흡수 등의 생리학적 연관성을 반영한 결측치 보정을 수행한다. KNN imputation이나 matrix factorization과 달리, MICE는 각 변수의 예측 모델을 반복적으로 업데이트하여 복잡한 비선형 관계까지 포착하고 불확실성을 고려한 다중 데이터셋을 생성한다.

4.2.4 Cost-sensitive Learning and Focal Loss

의료 진단에서 실제 환자 분포는 불균형하며, 단순 oversampling은 소수 클래스의 합성 샘플을 생성하여 실제 임상 분포를 왜곡시킴을 확인하였다. 또한, Undersampling은 다수 클래스의 중요한 패턴을 손실시켜 일반화 성능을 저하시킨다.

따라서 Cost-sensitive Learning를 사용하여 오분류 비용을 차등 적용하여 실제 데이터 분포를 유지하면서도 모델이 희귀 클래스에 더 집중하도록 유도하였다. Focal Loss는 쉬운 샘플의 기여도를 감소시켜 분류가 어려운 경계 사례에 학습을 집중시키며, 두 기법의 결합은 class weight balancing이나 threshold moving 같은 후처리 방법보다 근본적이고 안정적인 해결책을 제공한다.

4.2.5 GroupKFold Cross-validation

의료 데이터는 동일 환자에서 시계열로 수집된 다중 관측치를 포함하며, 기존의 교차 검증은 같은 환자의 데이터가 훈련-검증 세트에 분산되어 데이터 누출을 발생시킨다. 이는 모델이 환자별 특이 패턴을 학습하여 과적합되고, 실제 성능을 과대평가하게 만든다. 의료 데이터는 이러한 과적합으로 인한 성능 과대 포장에 절대로 일어나서는 안되는 도메인으로, 최대한 강건한 모델을 만들기 위해 노력하였다.

4.3 Clinical Implications

본 프로젝트의 결과는 실시간 생체 신호 모니터링을 통한 긴장성 기흉의 조기 경보 시스템 구축 가능성을 제시한다. 특히 중환자실 환경에서 의식이 저하되거나 진정된 환자의 경우, 주관적 증상 호소가 어려워 임상적 악화의 조기 발견이 어렵다. 본 모델을 중환자실 모니터링 시스템에 통합할 경우, 의료진이 긴장성 기흉의 발생 가능성을 사전에 인지하고 신속한 진단 및 치료를 시작할 수 있어 환자 예후 개선에 기여할 수 있을 것으로 기대된다.

본 프로젝트에서 제안한 모델은 의료 데이터의 클래스 불균형, 환자 간 이질성, 시계열적 변동성 등 실제 중환자실 환경의 제약조건을 고려하여 다층적 규제 전략을 체계적으로 도입함으로써 임상 환경에서의 강건성을 극대화하도록 설계되었다. 손실 함수 수준에서는 Cost-sensitive Learning과 Focal Loss를 결합하여 클래스 불균형에 대한 알고리즘적 규제를 적용하였으며, 학습 과정에서는 early stopping으로 과적합을 방지하였다. 또한 XGBoost 모델의 내재적 규제 파라미터인 L1/L2 정규화, 트리 깊이 제한, 그리고 낮은 학습

를 Optuna 최적화를 통해 조정함으로써 모델 복잡도를 제어하였다. GroupKFold 교차 검증은 환자 단위 데이터 누출을 엄격히 방지하여 일반화 성능 평가의 신뢰성을 확보하는 구조적 규제로 작용하였다. 이러한 다단계 규제 전략을 통해 실제 중환자실에서 관찰되는 불안정한 데이터 분포 하에서도 안정적인 예측 성능을 유지하도록 설계하였다.

또한, 주요 예측 특성으로 식별된 호흡수의 침도, 쇼크 지수의 침도, 산소포화도의 변동성 등은 임상적으로 관찰 가능한 지표들이므로, 모델의 예측 결과에 대한 해석 가능성을 높여 의료진의 신뢰도를 확보할 수 있다. 이는 단순히 예측 정확도가 높은 모델을 제시하는 데 그치지 않고, 실제 임상 의사결정 과정에서 활용 가능한 의사결정 보조 도구로서의 잠재력을 강화한다. Permutation Importance 기반의 특성 선택 역시 모델의 복잡도를 256개에서 76개 특성으로 감소시켜 과적합을 방지하고 해석 가능성을 향상시키는 특성 수준의 규제로 작용하였다.

4.4 Limitations

본 프로젝트는 몇 가지 제한점을 가진다. 첫째, 흉관 삽입이라는 침습적 치료를 받은 환자를 긴장성 기흉의 대리 지표로 사용하였으나, 생리학적 정의에 따른 완벽한 긴장성 기흉(호기-흡기 전 구간의 지속적 양압)을 직접 검증하지는 않았다. 따라서 본 모델은 엄밀히 말해 임상적 개입이 필요한 기흉을 예측하는 것으로 해석되어야 한다. 둘째, 단일 기관의 데이터만을, 즉, 외부 검증 없이 교수님께서 제공해주신 MIMIC-IV 데이터셋만을 사용하여 외부 타당도 검증이 이루어지지 않았으므로, 다른 의료 기관에서의 일반화 가능성은 추가 검증이 필요하다. 셋째, 후향적 분석 설계로 인해 실제 임상 환경에서의 실시간 성능 평가가 이루어지지 않았다. 넷째, SILVER 코호트를 최종 학습에서 배제함으로써 경증 기흉에 대한 모델의 민감도가 제한될 수 있으며, 이는 조기 탐지 시스템의 적용 범위를 제한할 가능성이 있다.

5 Conclusion

본 프로젝트는 MIMIC-IV 데이터베이스를 활용하여 생체 신호 및 동맥혈 가스 분석 데이터로부터 긴장성 기흉의 조기 탐지 가능성을 검증하였다. 도메인 지식 기반의 특성 공학, 강건한 전처리 파이프라인, 그리고 불균형 데이터 학습에 최적화된 XGBoost 모델을 통해 AUROC 0.7457, Recall 0.7276의 성능을 달성하였다. 특히 급격한 생체 신호 변화를 나타내는 침도 특성과 최근 2시간 동안의 호흡수 및 산소포화도 변동성이 주요 예측 인자로 식별되었다.

본 프로젝트의 결과는 실시간 생체 신호 모니터링을 통한 긴장성 기흉의 조기 경보 시스템 구축 가능성을 제시하며, 중환자실 환경에서 생명을 위협하는 응급 상황에 대한 의료진의 신속한 대응을 지원할 수 있을 것으로 기대된다. 향후 다기관 외부 검증 및 전향적 임상 시험을 통해 실제 임상 환경에서의 유용성을 평가하고, 해석 가능성을 강화한 모델 개발이 필요하다.

References

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2623–2631. <https://doi.org/10.1145/3292500.3330701>

- Johnson, A. E. W., Bulgarelli, L., Shen, L., Gayles, A., Shammout, A., Horng, S., Pollard, T. J., Hao, S., Moody, B., Gow, B., Lehman, L.-w. H., Celi, L. A., & Mark, R. G. (2023). MIMIC-IV, a freely accessible electronic health record dataset [Database version 2.2]. *Scientific Data*, 10(1), 1. <https://doi.org/10.1038/s41597-022-01899-x>
- Johnson, A. E. W., Pollard, T. J., Shen, L., Lehman, L.-w. H., Feng, M., Ghassemi, M., Moody, B., Szolovits, P., Celi, L. A., & Mark, R. G. (2016). MIMIC-III, a freely accessible critical care database. *Scientific Data*, 3, 160035. <https://doi.org/10.1038/sdata.2016.35>
- Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2980–2988. <https://doi.org/10.1109/ICCV.2017.324>
- Rajkomar, A., Dean, J., & Kohane, I. (2019). Machine learning in medicine. *New England Journal of Medicine*, 380(14), 1347–1358. <https://doi.org/10.1056/NEJMr1814259>
- van Buuren, S., & Groothuis-Oudshoorn, K. (2011). Mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3), 1–67. <https://doi.org/10.18637/jss.v045.i03>